

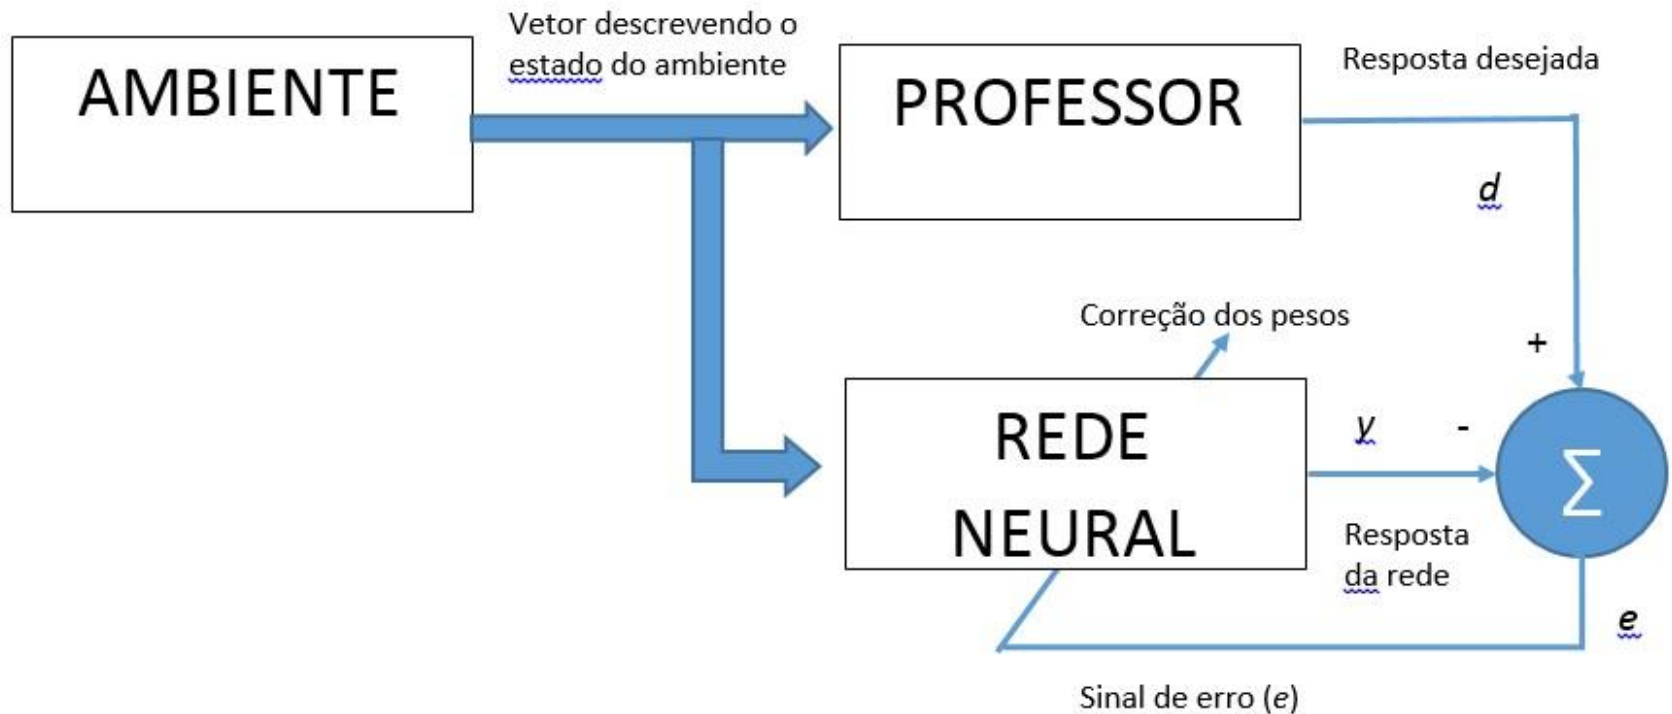


Aprendizado


- Determinação da intensidade das conexões (pesos) entre os neurônios através do algoritmo de aprendizagem.

Aprendizagem Supervisionada

- Conjunto de exemplos entrada-saída (professor)



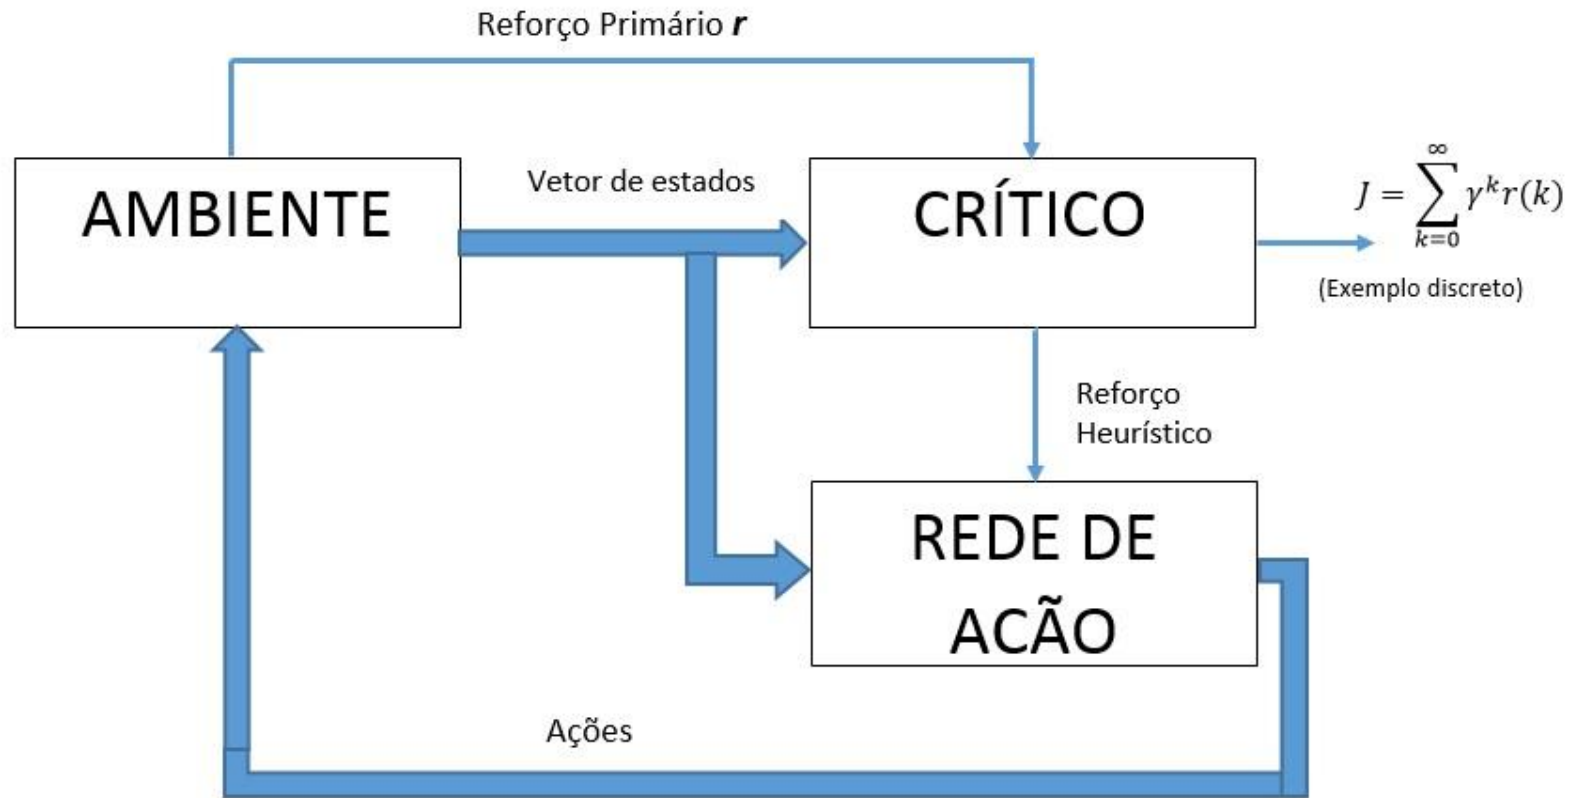
Aprendizagem não Supervisionada



- Não há professor (somente entradas disponíveis);
- A rede é sintonizada com as regularidades estatísticas dos dados de entrada, desenvolvendo a habilidade de formar representações internas para codificar caracteres de entrada e criar novas classes, ou grupos, que representam tais regularidades;
- Só é possível utilizar-se tal aprendizagem quando existe redundância nos dados de entrada (sem redundância seria impossível encontrar quaisquer padrões ou características dos dados de entrada);
- Exemplos: estágios iniciais da visão e audição.

Aprendizagem por Reforço (Sutton/Barto)

- Minimização/maximização de um critério de desempenho baseado em um sinal do ambiente (reforço primário: bom/ruim).






Aprendizagem supervisionada

- 1958 → Perceptron de Frank Roseblatt;
- Teorema de convergência do perceptron mostra que um neurônio de McCulloch e Pitts treinado como o algoritmos de treinamento (aprendizagem) do perceptron sempre converge caso o problema seja linearmente separável.

Algoritmo de aprendizagem do perceptron



$$\mathbf{w}(n+1) = \mathbf{w}(n) + \Delta \mathbf{w}(n) \quad (\mathbf{w} = \text{vetor})$$

$$e = d - y, d = \text{saída desejada para o padrão } [x_1 \ x_2 \ \dots \ x_n]^T$$

$$\Delta \mathbf{w} = \eta \cdot e \cdot \mathbf{X}, \text{ (baseado na regra de Hebb originalmente)}$$

$\eta = \text{taxa de aprendizagem (influi no tempo de convergência)}$

$0 \leq \eta \leq 1$, $\uparrow \eta \rightarrow \text{aprendizado oscila ou não converge}$

$\downarrow \eta \rightarrow \text{demora mais para realizar o aprendizado}$

Equação geral dos pesos do neurônio do perceptron:

$$\mathbf{w}(n+1) = \mathbf{w}(n) + \eta \cdot e \cdot \mathbf{X} \quad (\mathbf{w}, \mathbf{X} = \text{vetor})$$



Algoritmo


- Obs: 1 perceptron
 - 1- Inicializar η e w ;
 - 2- Repetir
 - Para cada par do conjunto de treinamento $\Gamma = \{X^i, y^i_{desejado}\}_{i=1}^p$
 - Atualizar o vetor de pesos segundo a regra
 - $w(n+1) = w(n) + \eta e X(n)$; $X(n) = X^i, i=1$ a p (*atualiza padrão a padrão*)
 - ou
 - $w(n+1) = w(n) + \eta \sum_{i=1}^p e^i X^i$; *modo batelada- batch*
 - Até $e = 0$ para todos os p elementos do conjunto de treinamento

O algoritmo de treinamento do perceptron sempre chega a uma solução para o problema de separação de duas classes linearmente separáveis em um tempo finito (finitas iterações).

Exemplo

Aplicação a um problema de reconhecimento de padrões (2 classes linearmente separáveis)

Exemplo com 4 entradas
treinado para separar
2 classes representadas pelos
vetores



$$\begin{cases} \mathbf{x}^1 = [+1 & x_1 & x_2 & x_3 & x_4]^T, d^1 = +1 \\ \mathbf{x}^2 = [+1 & 0,1 & 0,2 & -0,3 & 0,9]^T, d^2 = -1 \end{cases}$$

→ apenas 2 vetores → linearmente separáveis



Exemplo (cont.)

Supondo $\eta = 0,03$ e $W(0) = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$ e MODO BATELADA

Exemplo (n=0)

• Para n=0 : $W(1) = W(0) + \eta \sum_{i=1}^2 e^i x^i$

$i=1 \Rightarrow x^1 \Rightarrow e^1 = d_1 - y = 1 - y (0 + 0 + 0 + 0 + 0) = 1 - 1 = 0$

$n=2 \Rightarrow x^2 \Rightarrow e^2 = d_2 - y = -1 - y (0) = -1 - 1 = -2$

$$W(1) = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} + 0,03 \times \left\{ 0 \times \begin{bmatrix} 1 \\ -0,1 \\ 0,4 \\ -0,7 \\ -1,8 \end{bmatrix} - 2 \times \begin{bmatrix} 1 \\ 0,1 \\ 0,2 \\ -0,3 \\ -0,9 \end{bmatrix} \right\} = \begin{bmatrix} -0,06 \\ -0,006 \\ -0,012 \\ +0,018 \\ +0,054 \end{bmatrix}$$

$e^1 = 0, e^2 \neq 0 \Rightarrow \text{continua!}$

Exemplo (n=1)

• Para $n=1$: $W(2) = W(1) + \eta \sum_{i=1}^2 e^i x^i$

$i=1 \Rightarrow x^1 \Rightarrow e^1 = 1 - y [-0,06(1) - 0,006(-0,1) - 0,012(0,4) + 0,018(-0,7) + 0,054(-1,8)]$

$e^1 = 1 - (-1) = 2$ (CONTINUA!)

$i=2 \Rightarrow x^2 \Rightarrow e^2 = -1 - y [-0,06(1) - 0,006(0,1) - 0,012(0,2) + 0,018(-0,3) + 0,054(-0,9)]$

$e^2 = -1 - (-1) = 0$

$$W(2) = \begin{bmatrix} -0,06 \\ -0,006 \\ -0,012 \\ 0,018 \\ 0,054 \end{bmatrix} + 0,03 \left\{ 2 \cdot \begin{bmatrix} 1 \\ -0,1 \\ 0,4 \\ -0,7 \\ -1,8 \end{bmatrix} + 0 \right\} = \begin{bmatrix} 0 \\ -0,12 \\ 0,012 \\ -0,024 \\ -0,054 \end{bmatrix}$$

Exemplo (n=2)

• Para n=2 $w(3) = w(2) + \eta \sum_{i=1}^2 \ell^i x^i$

$i=1 \Rightarrow x^1 \Rightarrow \ell^1 = 1 - \eta [0(1) - 0,12(-0,1) + 0,012(0,4) - 0,024(-0,7) - 0,054(-1,3)]$
 $\ell^1 = 1 - 1 = 0$

$i=2 \Rightarrow x^2 \Rightarrow \ell^2 = -1 - [0(2) - 0,12(0,1) + 0,012(0,2) - 0,024(-0,3) - 0,054(-0,9)]$
 $\ell^2 = -1 - 1 = -2$ (CONTINUA !)

$w(3) = \begin{bmatrix} 0 \\ -0,12 \\ 0,012 \\ -0,024 \\ -0,054 \end{bmatrix} + 0,03 \times \left\{ 0 - 2 \begin{bmatrix} 1 \\ 0,1 \\ 0,2 \\ -0,3 \\ -0,9 \end{bmatrix} \right\} = \begin{bmatrix} -0,06 \\ -0,126 \\ 0 \\ -0,006 \\ 0 \end{bmatrix}$

Exemplo (n = 3)

• para $n=3$: $W(4) = W(3) + \eta \sum_{i=1}^2 x^i x^i$

$1=1 \Rightarrow x^1 \Rightarrow l^1 = 1 - \eta [-0,06(1) - 0,126(-0,1) + 0 - 0,006(-0,7) + 0]$
 $l^1 = 1 - (-1) = 2$ (continua!)

$1=2 \Rightarrow x^2 \Rightarrow l^2 = -1 - \eta [-0,06(1) - 0,126(0,1) + 0 - 0,006(-0,3) + 0]$
 $l^2 = -1 - (-1) = 0$

$$W(4) = \begin{bmatrix} -0,06 \\ -0,126 \\ 0 \\ -0,006 \\ 0 \end{bmatrix} + 0,03 \left\{ 2 \begin{bmatrix} 1 \\ -0,1 \\ 0,4 \\ -0,7 \\ 1,8 \end{bmatrix} + 0 \right\} = \begin{bmatrix} 0 \\ -0,132 \\ 0,024 \\ -0,048 \\ -0,108 \end{bmatrix}$$

Exemplo (n=4)

* para $n=4$: $w(5) = w(4) + \eta \sum_{i=1}^2 x^i x^i$

$i=1 \Rightarrow x^1 \Rightarrow x^1 = 1 - \eta [0(1) - 0,132(-0,1) + 0,024(0,1) - 0,048(-0,7) - 0,108(-1,8)]$
 $x^1 = 1 - 1 = 0$

$i=2 \Rightarrow x^2 \Rightarrow x^2 = -1 - \eta [0(1) - 0,132(0,1) + 0,024(0,2) - 0,048(-0,3) - 0,108(-0,9)]$
 $x^2 = -1 - 1 = -2$ (continua)

$$w(5) = \begin{bmatrix} 0 \\ -0,132 \\ 0,024 \\ -0,048 \\ -0,108 \end{bmatrix} + 0,03 \left\{ 0 - 2 \begin{bmatrix} 1 \\ 0,1 \\ 0,2 \\ -0,3 \\ -0,9 \end{bmatrix} \right\} = \begin{bmatrix} -0,06 \\ -0,138 \\ 0,012 \\ -0,030 \\ -0,054 \end{bmatrix}$$

Exemplo (fim)

• para $n=5$: $W(6) = W(5) + \eta \sum_{i=1}^2 e^i x^i$


$l=1 \Rightarrow x^1 \Rightarrow e^1 = 1 - y [-0,06(1) - 0,138(-0,1) + 0,012(0,4) / 0,030(-0,7) - 0,054(-1,8)]$
 $e^1 = 1 - 1 = 0 //$

$l=2 \Rightarrow x^2 \Rightarrow e^2 = -1 - y [-0,06(1) - 0,138(0,1) / 0,012(0,2) - 0,030(-0,3) - 0,054(-0,9)]$
 $e^2 = -1 + 1 = 0 //$


$e^1, e^2 = 0 \Rightarrow \text{FIM}$

TREINOU COM 5 ITERAÇÕES

PERCEPTRON:



Algoritmo LMS



- Neurônio Linear;
- Mesma regra de aprendizagem do perceptron;
- Aplicações: predição, filtragem adaptativa;
- Baseado em algoritmo de correção de erro;
- Aprendizagem contínua.

Redes Perceptron Multicamada (MLP)

- MLP → "Multi-Layer Perceptron";
- Rede tipo *Feedforward*;
- Padrões não precisam ser linearmente separáveis;
- Podemos ter n camadas escondidas;
- Como treinar os pesos das camadas intermediárias? R: algoritmo de retropropagação do erro (*backpropagation*) → próxima aula!

